İNÖNÜ ÜNİVERSİTESİ YAPAY SİNİR AĞLARI DERSİ MAKALE SUNUMU

An Introductory Review of Deep Learning for Prediction Models With Big Data

Ad Soyad: Elif AKYOL
Öğrenci Numarası: 02220224019

Makalenin Konusu

Bu makale, derin öğrenmenin büyük veri ile çalışan tahmin modellerindeki yerini açıklayan giriş niteliğinde bir derleme çalışmasıdır.
Makalenin temel amacı, derin öğrenmenin en önemli mimarilerini anlaşılır bir şekilde tanıtmaktır.

Makalede özellikle şu yapılar ele alınmaktadır:

- Deep Feedforward Neural Networks (D-FFNN)
- Convolutional Neural Networks (CNN)
- Deep Belief Networks (DBN)
- Autoencoders (AE)
- Long Short-Term Memory (LSTM)

Makalenin Amacı

Makalenin amacı, derin öğrenmenin temel mantığını ve önemli mimarilerini açıklamaktır.
Ayrıca her modelin hangi veri türlerinde ve hangi problemlerde daha etkili olduğunu göstermeyi hedeflemektedir.

Bu çalışma, özellikle derin öğrenmeye yeni başlayan kişiler için açıklayıcı bir kaynak niteliğindedir.

Derin Öğrenme Neden Önemlidir?

Günümüzde görüntü, ses, metin, biyolojik veri ve sensör verisi gibi çok büyük ve karmaşık veri türleri oluşmaktadır.
Bu verilerin analiz edilmesi klasik yöntemlerle zorlaşmaktadır.

Derin öğrenme bu noktada öne çıkar çünkü:

- Ham veriden otomatik olarak özellik öğrenebilir
- Elle özellik çıkarma ihtiyacını azaltır
- Büyük ve karmaşık verilerde başarılı sonuçlar verir

Bu nedenle görüntü işleme, konuşma tanıma ve doğal dil işleme gibi alanlarda çok yaygın kullanılmaktadır.

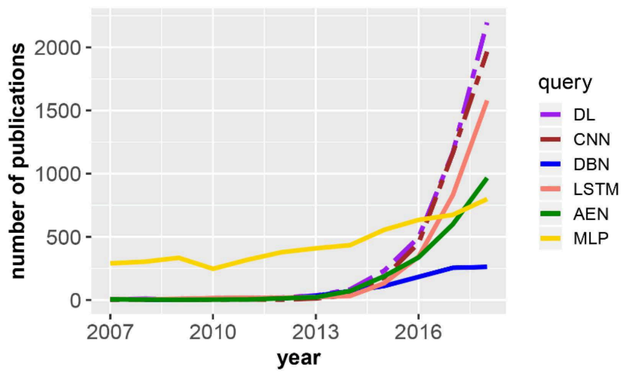

FIGURE 1 | Number of publications in dependence on the publication year for DL, deep learning; CNN, convolutional neural network; DBN, deep belief network; LSTM, long short-term memory; AEN, autoencoder; and MLP, multilayer perceptron. The legend shows the search terms used to query the Web of Science publication database. The two dashed lines are scaled by a factor of 5 (deep learning) and 3 (convolutional neural network).

Görsel: Derin öğrenme yayınlarının artışını gösteren grafik

Derin Öğrenmenin Tarihsel Gelişimi

Makale, sinir ağlarının tarihsel gelişimine de yer vermektedir.
Yapay nöron fikri 1940'lı yıllarda ortaya çıkmış, daha sonra perceptron, backpropagation, Hopfield ağı, Boltzmann makineleri ve LSTM gibi gelişmelerle ilerlemiştir.

Özellikle:

- **2006**: Derin öğrenmenin yeniden yükselişe geçtiği dönem
- **2012**: AlexNet başarısıyla CNN'lerin büyük popülerlik kazanması

Bu gelişmeler derin öğrenmeyi yapay zekânın merkezine taşımıştır.

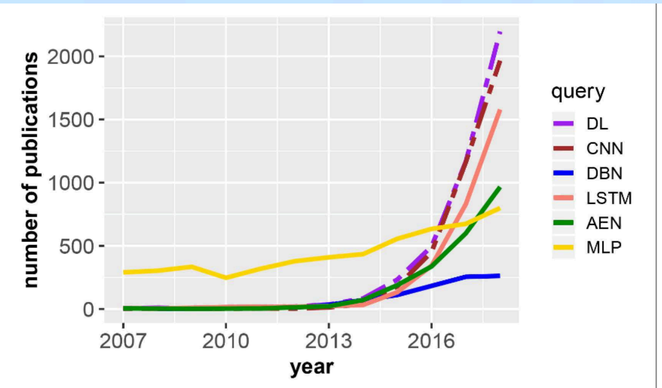

FIGURE 1 | Number of publications in dependence on the publication year for DL, deep learning; CNN, convolutional neural network; DBN, deep belief network; LSTM, long short-term memory; AEN, autoencoder; and MLP, multilayer perceptron. The legend shows the search terms used to query the Web of Science publication database. The two dashed lines are scaled by a factor of 5 (deep learning) and 3 (convolutional neural network).

Görsel: Tarihsel gelişim şeması veya yayın grafiği

Yapay Nöron ve Temel Mantık

Makale önce yapay nöronun temel yapısını açıklar.
Bir yapay nöron:

- Giriş verilerini alır
- Ağırlıklarla çarpar
- Bias ekler
- Sonucu aktivasyon fonksiyonundan geçirir
- Çıktı üretir

Sık kullanılan aktivasyon fonksiyonları:

- ReLU
- Sigmoid
- Tanh
- Softmax

Bu yapı, tüm derin öğrenme modellerinin temelini oluşturmaktadır.

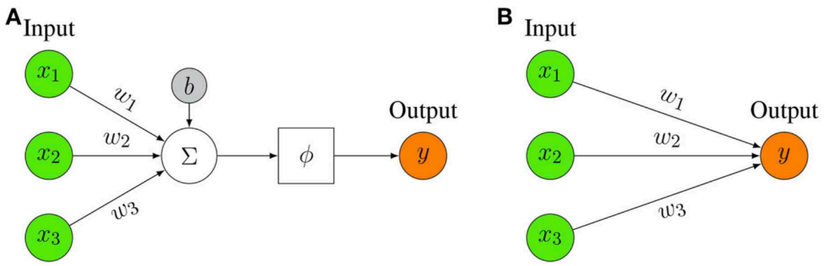

FIGURE 2 | (A) Representation of a mathematical artificial neuron model. The input to the neuron is summed up and filtered by activation function ϕ (for examples see **Table 1**). **(B)** Simplified Representation of an artificial neuron model. Only the key elements are depicted, i.e., the input, the output, and the weights.

Görsel: Yapay nöron modeli

Deep Feedforward Neural Networks (D-FFNN)

D-FFNN, çok katmanlı ileri beslemeli sinir ağlarıdır.
Bu ağlarda bilgi giriş katmanından çıkar, gizli katmanlardan geçer ve çıktı katmanına ulaşır.

Makaleye göre bu ağların önemi şudur:

- Karmaşık ilişkileri öğrenebilirler
- Çok katman sayesinde daha güçlü temsil oluştururlar
- Genel amaçlı tahmin problemlerinde kullanılabilirler

Bu ağların eğitiminde genellikle:

- Backpropagation
- Stochastic Gradient Descent kullanılır.

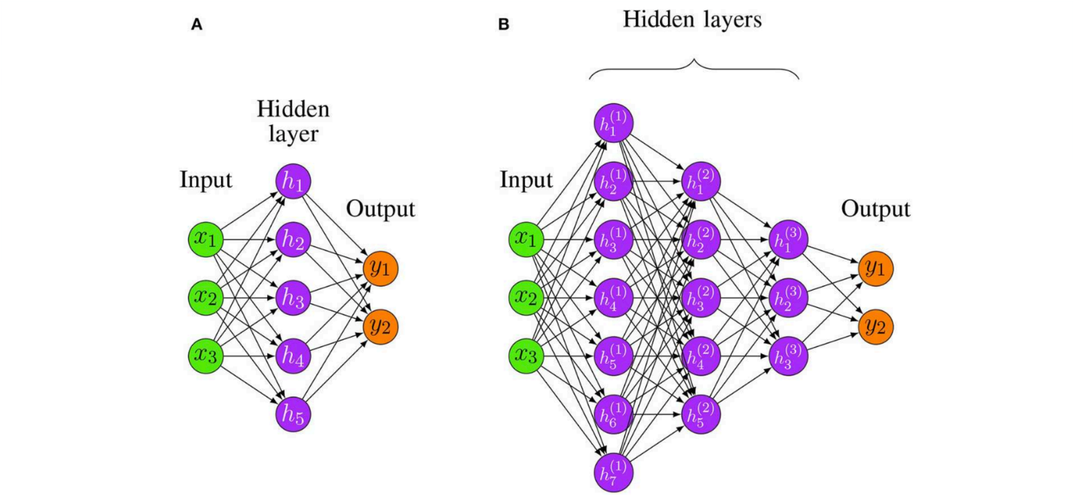

IRE 3 | Two examples for Feedforward Neural Networks. **(A)** A shallow FFNN. **(B)** A Deep Feedforward Neural Network (D-FFNN) with 3 hidden layers.

Görsel: Shallow FFNN ve Deep FFNN karşılaştırması

Convolutional Neural Networks (CNN)

CNN, özellikle görüntü verileri için geliştirilmiş bir derin öğrenme modelidir.
Klasik tam bağlı ağlardan farklı olarak her nöron tüm veriye değil, sadece küçük bir bölgeye odaklanır.

CNN'in temel avantajları:

- Yerel özellikleri öğrenebilmesi
- Ağırlık paylaşımı sayesinde daha az parametre kullanması
- Görüntü verilerinde yüksek başarı sağlaması

Bu nedenle CNN'ler bilgisayarlı görü alanında en çok kullanılan modellerden biridir.

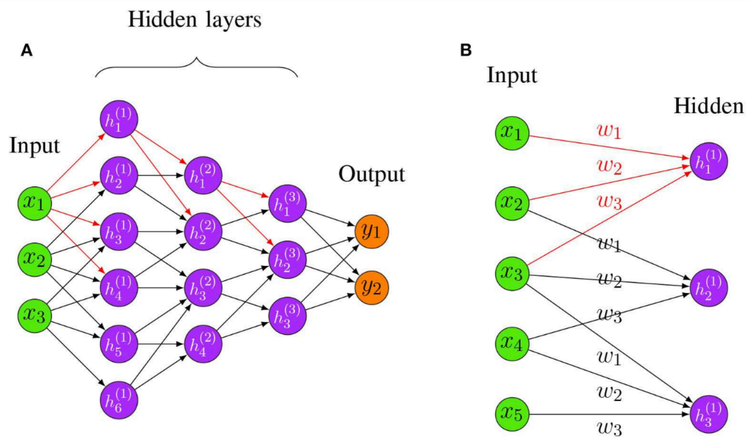

FIGURE 4 | (A) An example for a Convolutional Neural Network. The red edges highlight the fact that hidden layers are connected in a "local" way, i.e., only very few neurons connect the succeeding layers. **(B)** An example for shared weights and local connectivity in CNN. The red edges highlight the fact that hidden layers are connected in a "local" way, i.e., only very few neurons connect the succeeding layers. The labels w_1, w_2, w_3 indicate the assigned weight for each connection, three hidden nodes share the same set of weights w_1, w_2, w_3 when connecting to three local patches.

Görsel: CNN local connectivity ve weight sharing şeması

CNN'in Temel Bileşenleri

CNN yapısında üç temel bölüm öne çıkar:

1. Convolution Katmanı

Girdi üzerinde filtreler dolaştırılarak özellik çıkarılır.

2. Pooling Katmanı

Boyutu küçültür, önemli bilgileri korur.

3. Fully Connected Katman

Son aşamada sınıflandırma yapılır.

Makale ayrıca **stride**, **zero-padding** ve **kernel** gibi kavramların CNN performansı için önemli olduğunu vurgular.

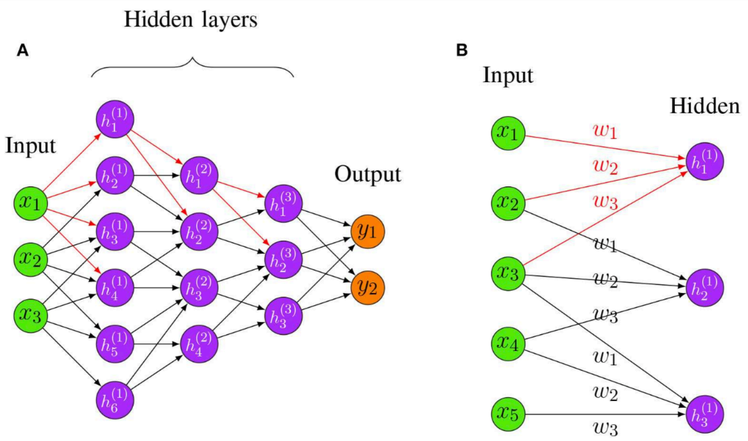

FIGURE 4 | (A) An example for a Convolutional Neural Network. The red edges highlight the fact that hidden layers are connected in a "local" way, i.e., only very few neurons connect the succeeding layers. **(B)** An example for shared weights and local connectivity in CNN. The red edges highlight the fact that hidden layers are connected in a "local" way, i.e., only very few neurons connect the succeeding layers. The labels w_1, w_2, w_3 indicate the assigned weight for each connection, three hidden nodes share the same set of weights w_1, w_2, w_3 when connecting to three local patches.

Görsel: CNN local connectivity ve weight sharing şeması

CNN Varyantları

Makale, CNN'in farklı gelişmiş türlerinden de bahsetmektedir:

- **VGGNet**
- **GoogLeNet**
- **ResNet**

Bu modellerin geliştirilme amacı:

- Daha derin ağlar kurmak
- Parametre sayısını azaltmak
- Performansı artırmak

Özellikle ResNet, residual bağlantılar sayesinde çok derin ağların eğitilmesini kolaylaştırmıştır.

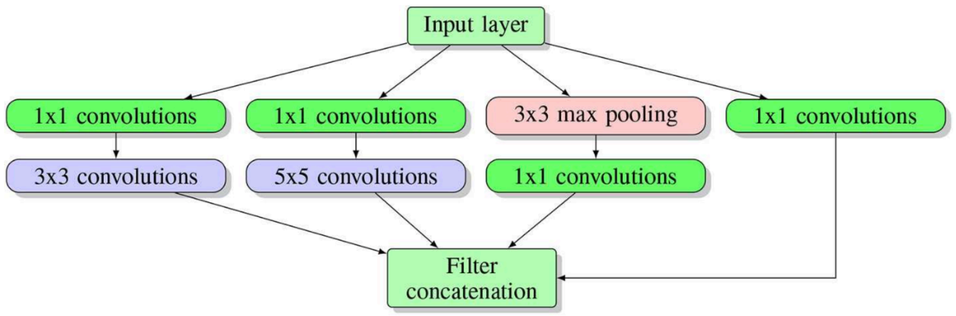

FIGURE 6 | Inception block structure. Here multiple blocks are stacked on top of each other, forming the input layer for the next block.

Görsel: Inception block veya ResNet residual block

Deep Belief Networks (DBN)

DBN, derin öğrenmenin erken dönem önemli modellerinden biridir.
Genellikle Restricted Boltzmann Machine (RBM) katmanlarının birleşiminden oluşur.

Makaledeki temel vurgu şudur:

- Önce denetimsiz ön eğitim yapılır
- Sonra ağ denetimli şekilde ince ayar ile eğitilir

Bu yaklaşım, derin ağların daha etkili öğrenmesine katkı sağlamıştır.

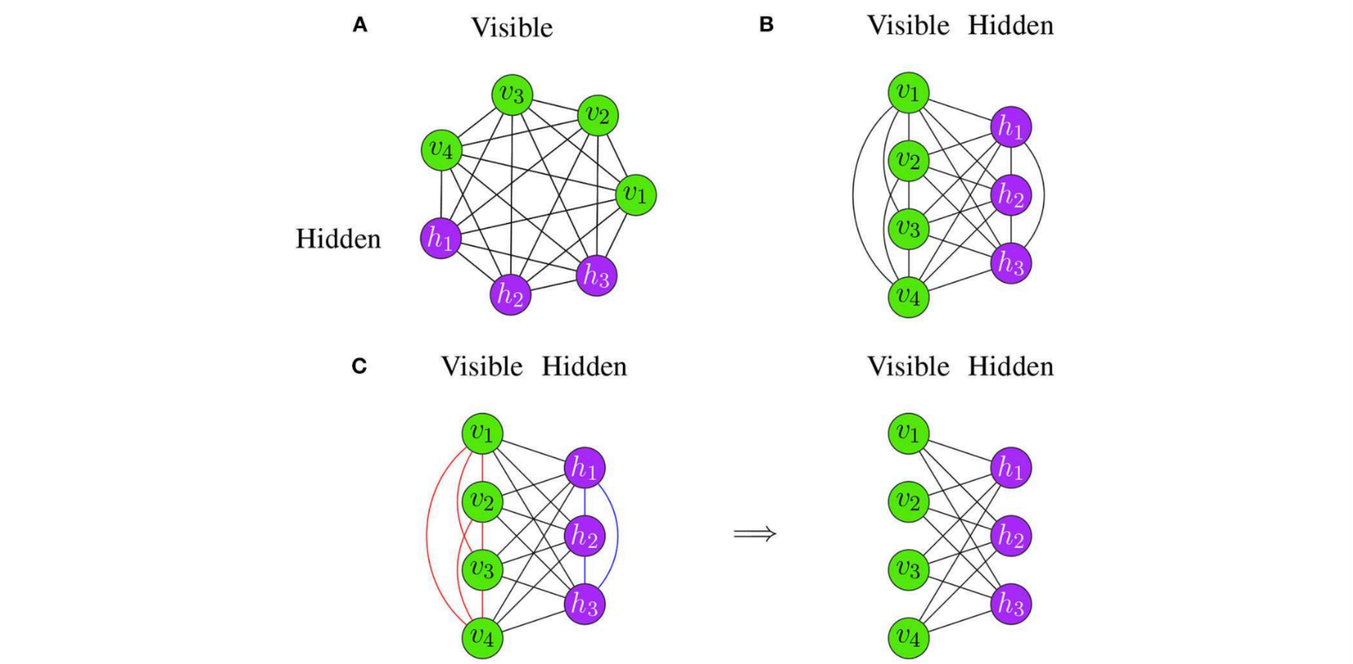

FIGURE 8 | Examples for Boltzmann Machines. **(A)** The neurons are arranged on a circle. **(B)** The neurons are separated according to their type. Both Boltzmann Machines are identical and differ only in their visualization. **(C)** Transition from a Boltzmann Machine (left) to a Restricted Boltzmann Machine (right).

Görsel: Boltzmann Machine ve RBM yapısı

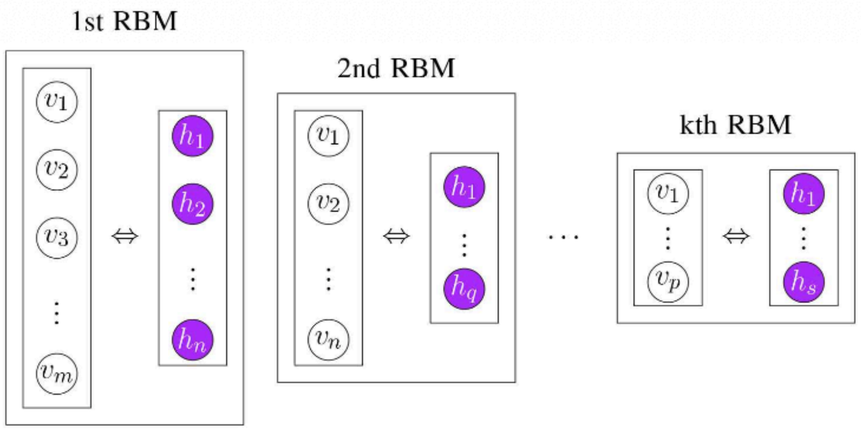

FIGURE 10 | Visualizing the stacking of RBMs in order to learn the parameters Θ of a model in an unsupervised way.

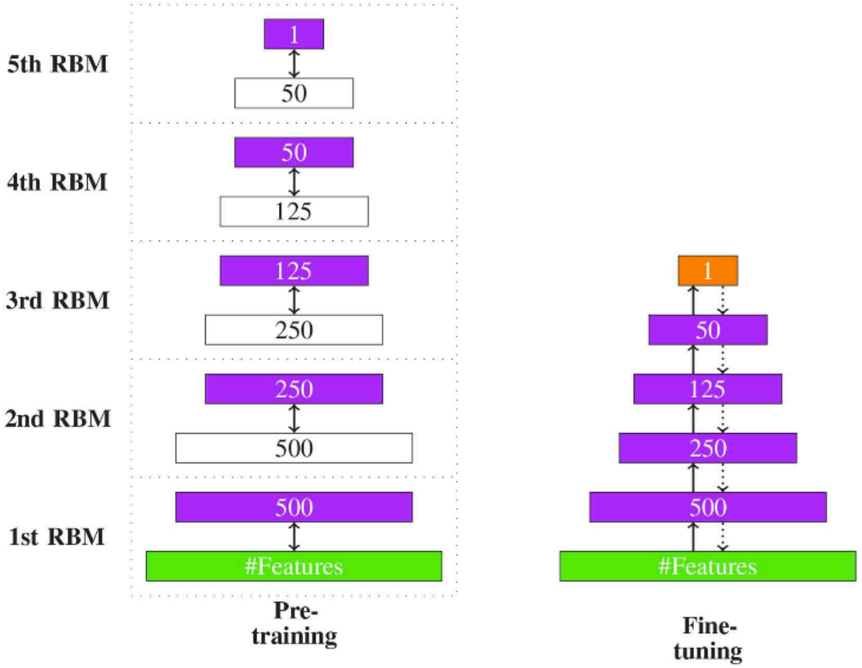

FIGURE 11 | The two stages of DBN learning. **(Left)** The hidden layer (purple) of one RBM is the input of the next RBM. For this reason their dimensions are equal. **(Right)** The two edges in fine-tuning denote the two stages of the backpropagation algorithm: the input feedforwarding and the error backpropagation. The orange layer indicated the output.

Autoencoders

Autoencoder, veriyi sıkıştırıp yeniden üretmeye çalışan bir yapıdır.
Amaç, verinin en önemli özelliklerini öğrenmektir.

Autoencoder'ın kullanım alanları:

- Özellik çıkarımı
- Boyut indirgeme
- Gürültü giderme
- Temsil öğrenme

Makaleye göre autoencoder'lar denetimsiz öğrenmede oldukça önemli bir yere sahiptir.

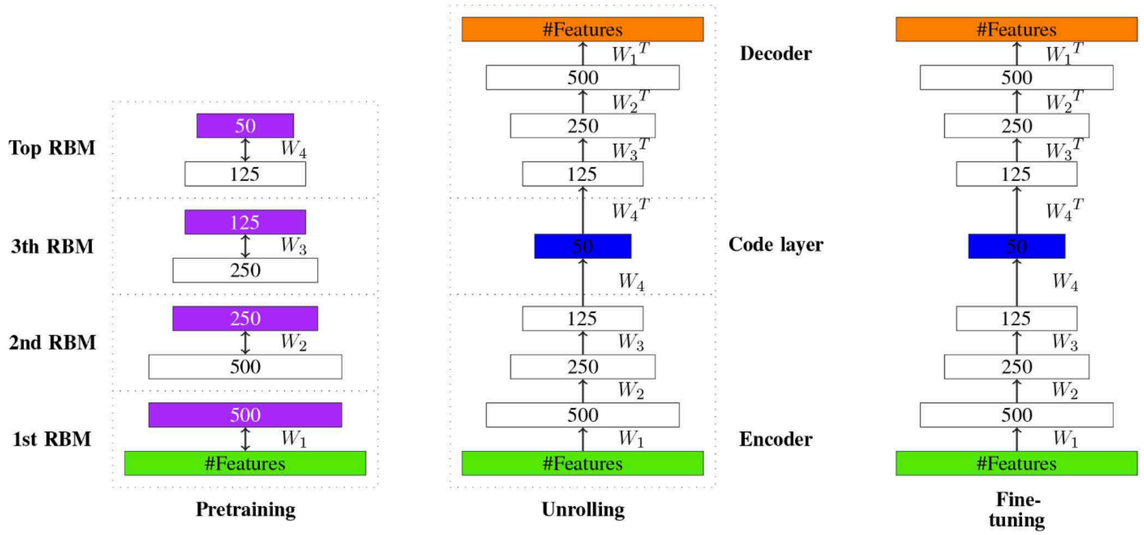

FIGURE 12 | Visualizing the idea of autoencoder learning. The learned new encoding of the input is represented in the code layer (shown in blue).

Görsel: Encoder–decoder yapısı

Long Short-Term Memory (LSTM)

LSTM, sıralı veriler için geliştirilmiş özel bir tekrarlayan sinir ağı türüdür.
Klasik RNN'lerde görülen uzun bağımlılıkları öğrenme sorununu çözmek amacıyla geliştirilmiştir.

LSTM'nin temel avantajları:

- Bilgiyi uzun süre saklayabilmesi
- Gereksiz bilgiyi unutabilmesi
- Zaman bağımlı verilerde etkili olması

Kullanım alanları:

- Metin işleme
- Dil modelleme
- Konuşma işleme
- Zaman serisi analizi

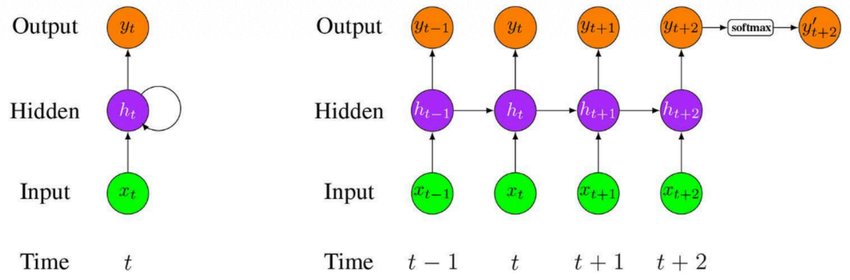

FIGURE 13 | (Left) A folded structure of a LSTM network model. **(Right)** An unfolded structure of a LSTM network model. x_i is the input data at time i and y_i is the corresponding output (i is the time step starting from $(t-1)$). In this network, only y'_{t+2} activated by softmax function is the final network output.

Görsel: LSTM hücre yapısı

Makalenin Temel Mesajı

Makalenin en önemli mesajı şudur:

Derin öğrenme, ham veriden otomatik olarak anlamlı temsiller öğrenebilen güçlü bir yaklaşımdır.
Farklı veri türleri için farklı derin öğrenme modelleri daha uygundur.

Örnek olarak:

- **CNN** → görüntü verileri
- **LSTM** → sıralı ve zaman bağımlı veriler
- **Autoencoder** → temsil öğrenme ve boyut indirgeme
- **D-FFNN** → genel tahmin problemleri
- **DBN** → ön eğitim tabanlı derin yapılar

Makalenin Değerlendirmesi

Makale, derin öğrenmenin çok güçlü olduğunu göstermektedir.
Ancak her problem için otomatik olarak en iyi çözüm olmadığını da belirtmektedir.

Dikkat edilmesi gereken noktalar:

- Büyük miktarda veri gerektirebilir
- Model seçimi veri türüne göre yapılmalıdır
- Bazı modeller yorumlanabilirlik açısından zayıf olabilir
- Küçük veri kümelerinde her zaman en iyi sonuç vermeyebilir

Bu nedenle doğru problem için doğru model seçmek önemlidir.

Sonuç

Sonuç olarak bu makale, derin öğrenmenin temel mimarilerini tanıtan kapsamlı bir giriş çalışmasıdır. Makale sayesinde farklı derin öğrenme modellerinin mantığı, kullanım alanları ve birbirlerinden farkları anlaşılabilmektedir.

Genel olarak çalışma, derin öğrenmenin büyük veri problemlerinde güçlü bir yaklaşım sunduğunu ve günümüz yapay zekâ uygulamalarında önemli bir yere sahip olduğunu göstermektedir.

TEŞEKKÜR EDERİM …